TAREA

KAFKA Y PROCESAMIENTO EN TIEMPO REAL

Autor: Jorge Centeno

Actualizado Enero 2025

OBJETIVO

El objetivo de la tarea es familiarizar al alumno con las tecnologías y herramientas del ecosistema Kafka aplicándolas a un caso de uso del mundo real.

DESCRIPCIÓN

FarmIA está integrando sensores IoT en los campos agrícolas para monitorizar datos como temperatura, humedad y fertilidad del suelo. También recopila datos en tiempo real sobre las transacciones de su plataforma de ventas en línea y quiere procesarlos para generar insights en tiempo real. La meta es construir un pipeline que procese estos datos de streaming y los transforme en información útil para la toma de decisiones y análisis.

La tarea consiste en construir una solución con Apache Kafka y su ecosistema que permita:

1. Procesar los datos de sensores agrícolas en tiempo real para detectar condiciones anormales (por ejemplo, temperatura muy alta o baja humedad).

2. Integrar los datos de transacciones de ventas provenientes de una base de datos relacional (MySQL) usando Kafka Connect.

3. Transformar los datos mediante procesamiento streaming para generar insights clave:
    a. alertas anomalías de los sensores.
    b. ventas por categoría de producto cada minuto.

INSTRUCCIONES

1. Crea los siguientes topics

- **sensor-telemetry**
  Contiene datos de los sensores agrícolas.

- **sales-transactions**
  Contiene datos de transacciones de ventas.

- **sensor-alerts**
  Contiene alertas generadas por el procesamiento de datos.

- **sales-summary**
  Contiene resumen de ventas agregadas por el procesamiento de datos.

2. Datasets de entrada

Datos de Sensores Agrícolas (IoT)

```
{
    "sensor_id": "sensor_001",
    "timestamp": 1673548200000,
    "temperature": 35.5,
    "humidity": 23.4,
    "soil_fertility": 78.2
}
```

Datos de Transacciones de Ventas

```
{
    "transaction_id": "tx12345",
    "timestamp": 1673548200000,
    "product_id": "prod_001",
    "category": "fertilizers",
    "quantity": 2,
    "price": 50.0
}
```

3. Tareas a resolver

Tarea 1: Generación de Datos Sintéticos con Kafka Connect

Configura un source connector Datagen que simule las lecturas de los sensores IoT

Output: Topic Kafka **sensor-telemetry**

Crea un schema avro que permita producir eventos de acuerdo a la estructura descrita en el punto anterior

Tarea 2: Integración de MySQL con Kafka Connect

Configura un source connector para leer datos de una base de datos relacional (MySQL) que contiene las transacciones de ventas.

Input: Tabla **transactions** con columnas: transaction_id, timestamp, product_id, category, quantity, price.

Output: Topic Kafka **sales-transactions**

Tarea 3: Procesamiento en Tiempo Real de sensores

Procesamiento de Datos de Sensores:

Escribe una aplicación de Flink/KSQLDB/KafkaStreams que procese los eventos del topic **sensor-telemetry**.

Cuando detecte condiciones anómalas (temperatura > 35 °C o humedad < 20 %) publicará un mensaje de alerta en el tema **sensor-alerts** con la siguiente estructura:

```
{
    "sensor_id": "sensor_001",
    "alert_type": "HIGH_TEMPERATURE",
    "timestamp": 1673548200000,
    "details": "Temperature exceeded 35°C"
}
```

Tarea 4: Procesamiento en Tiempo Real de transacciones de ventas

Resumen de Ventas por Categoría:

Escribe una aplicación de Flink/KSQLDB/KafkaStreams que procese el topic **sales-transactions**

Agregue los datos por categoría de producto y calcule el total de ingresos por categoría en intervalos de 1 minuto.

Publica el resumen en el topic **sales-summary** con el formato:

```
{
    "category": "fertilizers",
    "total_quantity": 20,
    "total_revenue": 1000.0,
    "window_start": 1673548200000,
    "window_end": 1673548260000
}
```

Tarea 5: Integración de MongoDB con Kafka Connect

Configura un sink connector para escribir los datos de las alertas en una colección sensor_alerts en un MongoDB.

Input: topic **sensor-alerts**

Output: Colección sensor_alerts en MongoDB

FORMATO Y ENTREGA

El entregable será una carpeta comprimida con todos los ficheros fuente de la solución y que además incluya un fichero README.md describiendo los pasos, tal y como hemos hecho en el repositorio de código de la asignatura. Considera incluir capturas de pantalla o pequeños videos si fuera necesario. Recuerda incluir

Incluye el código de la aplicación de Flink/KSQLDB/KafkaStreams

Incluye las configuración de Kafka Connect

Documenta todo el proceso en el fichero README.md

RÚBRICA DE EVALUACIÓN

Cada una de las cuatro tareas propuestas aporta un 20% de la nota total.